

当代人工智能 实验一：文本分类

10245501430 王婧秋

1 任务与设置

将 7368 条 Usenet 新闻组邮件分入 10 类（类别基本均衡），提交官方测试集 2457 条的预测。训练集按 70/15/15 分层划分为训练 5156 / 验证 1106 / 本地测试 1106 条（random_state=42）：验证集与开发集（训练+验证）上的 5 折分层 CV 用于全部比较与选择，本地测试集锁定方案后只评估一次。向量化器与分类器封装为同一 Pipeline，CV 每折重新拟合，预处理均为逐条规则，杜绝泄露。验证集准确率的标准误 $SE \approx 0.007$ ，因此采用 **1-SE 规则**：与最优者相差不到 1 个 SE 且 CV 不显著更低的方案视为等价，取最简单者。

2 方法

特征：删邮件头（保留 Subject）后做 TF-IDF， $w(t,d)=tf \cdot [\ln((1+N)/(1+df))+1]$ ，再 L2 归一化。**模型**：① MultinomialNB（加性平滑 α ）；② 线性 SVM（LinearSVC，平方合页损失，C 控制正则），另用 SVC 比较线性核与 RBF 核；③ MLP（ReLU 隐层 + softmax，Adam，L2 正则 α ，早停）。**改进**：① Subject 重复 3 次以加权标题词；② 拼接 char_wb 2-5 gram 字符特征，捕获词形变化与型号串（如 486dx2）；③ 三模型硬投票。

3 结果与分析




图 1 预处理消融与文本表示（柱：验证集；圆点：5 折 CV 均值±标准差；方块：NB 验证集）

- **删邮件头**一致有效（SVM 0.9313→0.9403，NB 0.9204→0.9403）；**删引用**有害（SVM -3.2、NB -5.3 个百分点），引文与本帖同话题。“头+噪声+词干”组合验证集最高（0.9421）但 CV（0.9377）反低于原文，说明单凭验证集挑组合会拟合噪声，最终只保留删邮件头。
- **IDF 是关键**：TF-IDF 0.9403 > TF 0.9123 > 0/1 0.8933 > 词频 0.8843。二元词组 CV 略高但维度增至 65 万，判为等价不采用；min_df=2 使维度 93579→34270 而性能不变。

表 1 三个模型调参结果与最终方案（耗时为单进程训练时间）

模型	选定参数	验证集	5 折 CV	本地测试 Acc / F1	参数量	耗时
MultinomialNB	$\alpha=0.1$	0.9412	0.9376±0.0065	0.9250 / 0.9261	0.34M	≈2 s
线性 SVM	C=0.3	0.9331	0.9348±0.0080	0.9385 / 0.9389	0.34M	≈2 s
MLP	(100,) , $\alpha=1e-4$	0.9430	0.9353±0.0083	0.9385 / 0.9394	3.43M	≈90 s
最终方案	SVM+Subject×3+字符 n-gram	0.9548	0.9495±0.0034	0.9530 / 0.9535	1.34M	≈60 s

- **三模型统计上无差异**：CV 相差不到 0.3 个百分点，逐折配对差小于其标准差（SVM-NB 为 -0.0027 ± 0.0042 ）；差别在代价，MLP 参数量 10 倍、耗时 30–60 倍。NB 与 SVM 的验证集曲线随正则减弱先升后降（图 2ab）；RBF 核（0.9286）与线性核（0.9250）相差不到 1 SE 却慢 20 倍以上。




图 2 调参曲线：(a)(b) 准确率随超参数变化（竖线为选定值）；(c) MLP 不早停时的逐轮训练过程




图3 全部候选方案的验证集与5折CV准确率（加粗为最终方案）

- **改进有效**：Subject×3 与字符 n-gram 单独使用各使 CV 提升 0.6–0.8 个百分点，组合后 CV 达 0.9495 ± 0.0034 ，领先其余候选 1 个标准差以上。**硬投票无效**（CV 0.9395）：SVM 的 74 个错误中 40 个三模型同错，错误高度相关。最终方案本地测试 0.9530，与验证集、CV 一致，未过拟合验证集。




图4 (a) 最终模型本地测试集混淆矩阵；(b) 三个基础模型验证集逐类 F1

- **误差与捷径**：错误集中于图形、Windows、PC 硬件三类（F1 0.86–0.90），“电子→PC 硬件”错分最多，多为话题本身跨类；签名中的 pitt、serdar、dod 等作者相关词权重很高，模型部分依赖“谁在发帖”，跨作者泛化存疑。

4 思考题

Q1 SVM/逻辑回归为何表现好？ 特征 34270 维而样本仅 5156 条，每篇平均 132.5 个非零特征（稀疏度 0.39%），训练集几乎线性可分（ $C \geq 1$ 时训练准确率 ≈ 1 ），线性边界已足够；逻辑回归与 LinearSVC 验证集同为 0.9331，印证关键在“线性”。调参后 NB 也不逊色：话题词区分度高时独立性假设代价有限。

Q2 调 MLP 结构或轮数能否提升？ 不能。加宽/加深后验证集 0.9376–0.9403，均低于 (100,)；不早停时验证集在第 7 轮达峰值 0.9448（图 2c），此后训练损失降到 0.009 而验证集回落至 0.941，呈过拟合。输入层权重占参数 99.97%，样本不足以约束； $\alpha = 1e-2$ 又会欠拟合（0.9313）。

Q3 其他文本表示？ 词袋（本实验低 5–6 个百分点）、n-gram（字符级有效）、静态词向量（Word2Vec/GloVe，稠密但平均会丢词序）、上下文预训练模型（BERT，更准但代价高几个数量级，本实验未验证）。

5 结论与局限

高维稀疏 TF-IDF 上，调参后的 NB、线性 SVM、MLP 统计上无差异，线性模型性价比最高；有效提升来自数据与特征（删邮件头、Subject 加权、字符 n-gram），最终本地测试准确率 0.9530。局限：选择规则在实验中途修订（仅用验证集与开发集）；字符 n-gram 未调参；特征以 SVM 为基准选取；模型仍依赖作者签名等捷径特征。